

MATA KULIAH STATISTIKA & PROBABILITAS
STATISTICAL HEALTH REPORT
Dosen Pengampu Ridho Kurniawan Pratama, S.Kom., M.T.I.



Intelligentia - Dignitas

Disusun Oleh:

Tsabita Nuriska Ramadhani (1519625050)
Daffa Raditia Nova (1519625058)
Muhammad Nafilham Athaya (1519625041)
Muhammad Yunus Setiaji (1519625043)
Muhammad Bintang Ramadhan(1519625031)

SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS NEGERI JAKARTA
2026

DAFTAR ISI

I. EXECUTIVE SUMMARY	1
II. DATA OVERVIEW.....	2
III. PARAMETER ESTIMATION	3
3.1 Maximum Likelihood Estimation (MLE)	4
3.2 Likelihood Visualization	4
3.3 Beta Posterior.....	5
IV. CONFIDENCE INTERVALS	6
V. HYPOTHESIS TESTING	7
VI. COMPUTATIONAL ANALYSIS.....	9
6.1 Monte Carlo Simulation (RQ3).....	10
6.2 Bloom Filter	10
6.3 MCMC - Knapsack.....	11
VII. RECOMMENDATIONS.....	11
7.1 Rekomendasi 1: Pertahankan Standar Review Saat Ini	12
7.2 Rekomendasi 2: Siapkan Kapasitas Tambahan Pasca Major Release.....	12
7.3 Rekomendasi 3: Terapkan Sistem Prioritisasi Bug Berbasis Data.....	12

I. EXECUTIVE SUMMARY

Poin 1 (Proses Review): Proses peninjauan kode (*code review*) berjalan produktif dengan tingkat keberhasilan *merge* Pull Request (PR) mencapai 62,09% ($\theta = 0,6209$). Pengelola repositori disarankan tetap mempertahankan standar peninjauan yang berlaku saat ini karena lebih dari 6 dari 10 PR berhasil diterima.

Poin 2 (Uji Hipotesis): Hasil uji hipotesis (Z-test, $p\text{-value} = 0,006$) membuktikan performa *merge* saat ini signifikan lebih tinggi daripada klaim historis lama (60%). Hal ini menunjukkan adanya peningkatan kualitas kontribusi dari komunitas.

Poin 3 (Lonjakan Data): Analisis mendeteksi adanya lonjakan drastis hingga 31 *issue* dalam seminggu (pencilan), yang biasanya terjadi pada periode pasca *major release*. Tim pengelola perlu mengalokasikan kapasitas bantuan tambahan pada masa-masa tersebut.

Poin 4 (Monte Carlo): Simulasi Monte Carlo menunjukkan peluang sebesar 66,77% bahwa suatu kendala (*issue*) akan memakan waktu lebih dari 30 hari untuk selesai ditutup. Angka ini mengonfirmasi adanya penumpukan (*backlog*) penyelesaian *bug* jangka panjang.

Poin 5 (Optimasi Sistem): Sebagai solusi, sistem prioritas berbasis MCMC Knapsack dapat digunakan untuk mengoptimalkan alokasi waktu penyelesaian kombinasi *bug*. Selain itu, integrasi struktur data *Bloom Filter* pada *pipeline triage* otomatis sangat layak diterapkan karena mampu menyaring laporan baru secara instan dengan tingkat *False Positive* yang sangat rendah (0,0034%).

II. DATA OVERVIEW

Data dikumpulkan dari repositori open-source pandas-dev/pandas melalui GitHub REST API v3 dengan rincian sebagai berikut.

2.1 Sumber Data

URL Repositori	http://pandas.pydata.org/
Metode Pengambilan	GitHub REST API v3
Endpoint	/repos/pandas-dev/pandas/issues
Parameter	state: all, per_page: 100, since: 2025-01-01
Rentang Tanggal	1 Januari 2025 – Mei 2026
Total Baris Data	7.044 baris
Format Raw	JSON (data/raw/dataset_raw.json)
Format Clean	CSV (data/clean/dataset.csv)

2.2 Keterbatasan Data

- Data hanya mencakup periode sejak 1 Januari 2025, sehingga tidak menggambarkan seluruh Riwayat repositori pandas sejak pertama kali dibuat.
- Pengambilan data dibatasi oleh rate limit Github API (5.000 request per jam dengan token).
- Variabel status merge (is_merged) untuk issues murni selalu bernilai 0 karena konsep merge hanya berlaku untuk Pull Request, bukan untuk issue biasa.
- Durasi penyelesaian issue/PR tidak dapat dihitung untuk data yang masih berstatus terbuka pada saat pengambilan data, karena belum memiliki tanggal penutupan.

III. PARAMETER ESTIMATION

3.1 Maximum Likelihood Estimation (MLE)

Penelitian ini bertujuan mengestimasi probabilitas keberhasilan *Pull Request* (PR) pada

RQ1: Berapa Probabilitas PR setelah berhasil di merge?

Variabel yang dianalisis bersifat biner, yaitu:

- 1 = PR berhasil di-merge
- 0 = PR tidak di-merge

Karena data bersifat biner, maka digunakan distribusi Bernoulli dengan parameter θ , yang merepresentasikan probabilitas sebuah PR berhasil di-merge.

Fungsi likelihood untuk distribusi Bernoulli adalah:

$$L(\theta) = \theta^k (1 - \theta)^{n-k}$$

dengan:

- k = jumlah PR yang berhasil di-merge
- n = total PR yang diamati

Untuk mempermudah perhitungan digunakan log-likelihood:

$$\ln L(\theta) = k \ln \theta + (n-k) \ln(1-\theta)$$

Turunan pertama terhadap θ :

$$\frac{d \ln L}{d\theta} = \frac{k}{\theta} - \frac{n-k}{1-\theta}$$

Dengan mensyaratkan:

$$\frac{d \ln L}{d\theta} = 0$$

maka diperoleh estimator Maximum Likelihood:

$$\hat{\theta} = \frac{k}{n}$$


Sesuai hasil perhitungan pada notebook, diperoleh:

$$\hat{\theta} = 0.62098$$

atau sekitar **62,1%**. Nilai tersebut menunjukkan bahwa probabilitas sebuah Pull Request berhasil di-merge pada repositori *pandas-dev/pandas* adalah sekitar **62,1%**.

3.2 Likelihood Visualization

Visualisasi likelihood dilakukan untuk melihat nilai parameter yang paling mungkin menghasilkan data yang diamati.



Berdasarkan grafik likelihood, puncak kurva berada pada nilai θ sekitar **0,621**. Hal ini menunjukkan bahwa nilai tersebut merupakan parameter yang memberikan likelihood maksimum terhadap data observasi. Hasil visualisasi ini konsisten dengan hasil perhitungan MLE yang diperoleh secara analitis.

3.3 Beta Posterior

Selain pendekatan frequentist melalui MLE, dilakukan juga estimasi Bayesian menggunakan distribusi Beta posterior. Dengan prior Beta(1,1), parameter posterior dihitung sebagai:

$$\alpha = k + 1 \quad \beta = n - k + 1$$

Hasil Perhitungan menghasilkan:

Parameter	Nilai
Alpha (α)	2511
Beta (β)	1533
Mean Posterior	0,6209
Mode Posterior	0,6210

IV. CONFIDENCE INTERVALS

4.1 Frequentist 95% Confidence Interval

Dalam paradigma **Frequentist**, parameter populasi (proporsi sebenarnya dari PR yang berhasil di-merge, disimbolkan dengan p) dianggap sebagai sebuah nilai konstanta yang tetap (*fixed*) tetapi tidak diketahui nilainya. Probabilitas dalam pandangan ini diartikan sebagai limit frekuensi relatif dalam jangka panjang jika eksperimen diulang tanpa batas.

- **Pendekatan Normal (Wald Interval):** Karena ukuran sampel sangat besar ($n > 4000$), teorema limit pusat (*Central Limit Theorem*) menjamin bahwa distribusi sampling dari proporsi sampel akan mendekati Distribusi Normal. Oleh karena itu, kita dapat menggunakan pendekatan Wald untuk menghitung selang kepercayaan: $CI = \theta \pm z(\alpha/2) \times \sqrt{\theta(1-\theta)/n}$
- **Interpretasi Hasil (0.6060 hingga 0.6359):** Rentang ini berarti kita 95% percaya bahwa proporsi sebenarnya dari PR yang di-merge berada di antara 60,60% dan 63,59%.
Catatan metodologis: Interpretasi Frequentist yang ketat **bukan** berarti ada peluang 95% nilai parameter berada di dalam rentang tersebut. Melainkan, jika kita mengambil sampel berukuran 4042 secara berulang-ulang dari populasi tersebut sebanyak ratusan kali dan membuat selang kepercayaan dari masing-masing sampel tersebut, maka 95% dari selang-selang kepercayaan yang terbentuk akan memuat parameter p yang asli.

4.2 Bayesian 95% Credible Interval

Paradigma **Bayesian** memiliki sudut pandang yang fundamental berbeda. Parameter populasi (p) tidak dianggap sebagai konstanta kaku, melainkan sebagai **variabel acak** yang memiliki distribusi probabilitas sendiri.

- **Distribusi Prior Beta(1,1):** Sebelum melihat data, analisis ini mengasumsikan ketidaktahuan total (*non-informative prior*) menggunakan distribusi Beta(1,1). Distribusi ini berbentuk seragam (*uniform flat*) di rentang $[0, 1]$, yang berarti peluang PR berhasil di-merge dianggap sama rata di setiap angka antara 0% hingga 100%.
- **Pembaruan Parameter (Posterior Update):** Ketika data observasi ($k=2510$ sukses, dan $n-k=1532$ gagal) dimasukkan, distribusi prior diperbarui menggunakan sifat konjugat (*conjugate prior*) dari fungsi Beta terhadap fungsi Likelihood Binomial. Sehingga menghasilkan **Distribusi Posterior Beta(2511, 1533)**.
- **Interpretasi Hasil (0.6059 hingga 0.6358):** Berbeda dengan Frequentist, **Selang Kredibel (Credible Interval)** Bayesian mengizinkan kita untuk membuat pernyataan probabilitas langsung terhadap parameternya: "*Berdasarkan data observasi dan prior yang digunakan, terdapat peluang sebesar 95% secara mutlak bahwa nilai proporsi PR yang berhasil di-merge berada di dalam rentang 60,59% hingga 63,58%.*"

V. HYPOTHESIS TESTING

Pada bab ini, dilakukan audit statistik inferensia formal untuk menguji karakteristik operasional pengelolaan kode pada repositori pandas-dev/pandas. Fokus utama pengujian diarahkan pada Research Question 2 (RQ2), yaitu menilai apakah proporsi Pull Request (PR) yang berhasil digabungkan (merged) ke dalam sistem mengalami pergeseran yang signifikan secara nyata dibandingkan dengan baseline atau klaim historis organisasi sebesar 60% ($p_0 = 0.60$). Pengujian ini dieksekusi menggunakan kerangka kerja Frequentist dengan Prosedur 6 Langkah (6-Step Procedure) yang ketat berdasarkan metodologi Tsun (2020) halaman 306.

5.1 Prosedur Uji Hipotesis 6 Langkah (RQ2)

Langkah 1: Formulasi Hipotesis Statistik Langkah awal adalah menentukan pernyataan hipotesis nol (H_0) dan hipotesis alternatif (H_a). Pengujian dilakukan secara dua arah (two-sided) untuk mendeteksi deviasi proporsi, baik berupa penurunan maupun peningkatan performa kerja:

- **$H_0: p = 0.60$** Proporsi dari total Pull Request yang berhasil di-merge pada repositori Pandas saat ini adalah sama dengan angka baseline historis, yaitu sebesar 60%.
- **$H_a: p \text{ tidak sama dengan } 0.60$** Proporsi dari total Pull Request yang berhasil di-merge pada repositori Pandas saat ini telah mengalami perubahan atau pergeseran yang signifikan secara statistik dari angka baseline historis 60%.

Langkah 2: Verifikasi Asumsi Data Sebelum melakukan komputasi, validitas uji statistik dikonfirmasi melalui pemenuhan asumsi dasar berikut:

1. **Independensi Sampel:** Data log aktivitas ditarik langsung dari basis data Git repositori Pandas, di mana keputusan penutupan atau penggabungan satu berkas PR tidak mendikte status berkas PR independen lainnya.
2. **Kecukupan Ukuran Sampel (Asumsi Normalitas):** Berdasarkan Teorema Limit Pusat (Central Limit Theorem), dengan ukuran sampel masif sebesar $n = 4042$, pengujian memenuhi kondisi normalitas secara mutlak karena nilai $n \times p_0$ lebih besar atau sama dengan 10 ($4042 \times 0.60 = 2425.2$) dan $n \times (1 - p_0)$ lebih besar atau sama dengan 10 ($4042 \times 0.40 = 1616.8$). Dengan demikian, distribusi sampling dari proporsi ini sah didekati dengan distribusi normal standar (Z).

Langkah 3: Perhitungan Statistik Uji Z Model matematika untuk uji Z satu sampel proporsi merujuk secara persis pada formula formal Tsun (2020) halaman 306, dengan penentuan standar deviasi yang dievaluasi di bawah kondisi hipotesis nol.

Berdasarkan ekstraksi data observasi, ditemukan nilai point estimate proporsi sampel ($\bar{x}$) sebesar **0.62098** (62.098%). Melalui pemanggilan fungsi otomatis pada modul `src/hypothesis.py`, diperoleh nilai statistik uji:

- **$Z\text{-statistic} = 2.7494$**

Langkah 4: Penentuan Wilayah Kritis dan P-value Pengujian ini menetapkan tingkat signifikansi $\alpha = 0.05$. Karena pengujian bersifat dua arah (two-sided), wilayah kritis penolakan berada pada ujung distribusi normal dengan batas nilai $Z < -1.96$ atau $Z > 1.96$. Berdasarkan fungsi akumulatif peluang komputasi, diperoleh nilai probabilitas empiris:

- **P-value = 0.0060**

Langkah 5: Keputusan Statistik Melalui perbandingan metrik, ditemukan bahwa nilai P-value (0.0060) jauh lebih kecil daripada ambang batas $\alpha = 0.05$. Secara spasial, posisi nilai Z-statistic (2.7494) juga telah masuk jauh ke dalam wilayah kritis penolakan ($Z > 1.96$). Oleh karena itu, keputusan statistik yang diambil secara mutlak dan tegas adalah **Reject H0 (Menolak Hipotesis Nol)**.

Langkah 6: Interpretasi Praktis dan Kesimpulan Engineering Pada tingkat kepercayaan 95%, terdapat bukti statistik yang sangat kuat untuk menolak hipotesis nol dan mendukung hipotesis alternatif. Hal ini menyimpulkan bahwa proporsi aktual Pull Request yang berhasil masuk ke dalam repositori utama Pandas (62.09%) berbeda secara nyata dari standar historis 60%.

Dari perspektif manajemen rekayasa perangkat lunak (software engineering), peningkatan angka integrasi kode ini mengindikasikan dua hal strategis bagi maintainer Pandas:

1. **Produktivitas Alur Kerja:** Sistem peninjauan kode (code review workflow) berjalan secara efisien dan responsif.
2. **Kualitas Kontribusi Komunitas:** Kontribusi kode yang dikirimkan oleh komunitas memiliki kesesuaian arsitektur yang tinggi terhadap basis kode (codebase) Pandas, sehingga berhasil lolos pengujian otomatis (CI/CD pipelines) tanpa memicu penumpukan penundaan (backlog).

5.2 Integrasi Antar-Lapisan (Cross-Layer Alignment)

Validitas hasil uji hipotesis Bab 5 ini terbukti konsisten secara matematis saat diintegrasikan dengan temuan pada bab-bab sekitarnya:

- **Sinkronisasi Mundur (Backward Linkage - Bab 4):** Member C menemukan bahwa dengan tingkat kepercayaan 95%, rentang interval parameter proporsi berada pada batas [0.6060, 0.6359]. Karena nilai klaim awal yang diuji ($p_0 = 0.6000$) berada sepenuhnya di luar rentang interval tersebut (di bawah batas bawah 0.6060), maka secara matematis hipotesis nol tersebut memicu keputusan penolakan (Reject H0).
- **Sinkronisasi Maju (Forward Linkage - Bab 6):** Angka keputusan penolakan ini memberikan justifikasi ilmiah bagi Member E untuk menolak model probabilitas statis lama. Nilai proporsi riil hasil uji (62.09%) ini langsung diserahkan sebagai parameter probabilitas empiris mutakhir untuk menggerakkan algoritma simulasi stokastik Monte Carlo sebanyak 50.000 iterasi pada berkas laporan berikutnya.

VI. COMPUTATIONAL ANALYSIS

Pada tahap dilakukan tiga teknik komputasional yang diterapkan untuk menjawab pertanyaan yang tidak dapat dijawab secara analitik oleh layer sebelumnya

6.1 Monte Carlo Simulation (RQ3)

RQ3: *Berapa probabilitas sebuah isu di pandas-dev/pandas membutuhkan lebih dari 30 hari untuk ditutup, diestimasi tanpa rumus analitik?*

Data `duration_days` bersifat sangat *skewed*, sehingga asumsi distribusi parametrik berisiko bias. Monte Carlo dipilih karena memungkinkan estimasi langsung dari distribusi real tanpa asumsi bentuk distribusi. Simulasi dilakukan sebanyak 50.000 *trial*, setiap *trial* mengambil satu sampel `duration_days` secara acak dari 1.929 *issues* yang telah ditutup dan mengecek apakah nilainya melebihi 30 hari.

Komponen	Nilai
Jumlah Trial	50.000
Estimasi $P(\text{duration} > 30 \text{ hari})$	0,6677
Standard Error	0,0021
Interval Estimasi 95%	[0,6635, 0,6718]

Terdapat probabilitas sebesar 66,77% bahwa sebuah *issue* membutuhkan lebih dari 30 hari untuk ditutup. Estimasi sangat stabil dengan *standard error* 0,0021 dan konvergen setelah sekitar 5.000 *trial*, konsisten dengan median durasi empiris 297 hari.

6.2 Bloom Filter

Untuk mengecek keanggotaan *bug report* secara efisien pada repositori berskala besar, pendekatan naif (menyimpan seluruh ID di memori) tidak praktis. *Bloom Filter* dipilih karena mampu menjawab *membership query* dengan memori sangat kecil. Diimplementasikan dengan $k = 5$ fungsi hash dan $m = 10.000$ bit, diisi 1.369 *issue number* berlabel *bug*. FPR teoritis dihitung menggunakan formula (Tsun 2020, hal. 329): $FPR = (1 - (1 - 1/m)^n)^k$.

Komponen	Nilai
Ukuran bit array (m)	10.000
Jumlah hash functions (k)	5

Jumlah item dimasukkan (n)	1.369
FPR Teoritis	0,000034 (0,0034%)

Bloom Filter tidak pernah menghasilkan *false negative*, jika filter menyatakan suatu *masalah* bukan *bug*, maka dapat dipastikan memang bukan *bug*. Tingkat *false positive* (FPR) secara teoritis sebesar 0,0034% tergolong sangat rendah. Ini membuktikan bahwa struktur data ini sangat layak dan aman diimplementasikan pada sistem *triage* otomatis untuk memproses *stream issue* dari GitHub tanpa membebani memori.

6.3 MCMC - Knapsack

Knapsack Problem bersifat NP-Hard, sehingga tidak praktis untuk data berskala besar. MCMC dengan algoritma Metropolis-Hastings dipilih karena mampu mengeksplorasi ruang solusi besar secara probabilistik tanpa mengevaluasi semua kombinasi (Tsun 2020, hal. 331). Simulasi menggunakan 15 bug issues representatif dengan kapasitas 9.000 hari.

Komponen	Nilai
Jumlah iterasi	100.000
Acceptance rate	0,3334 (33,34%)
Total value optimal	12 bug issues
Total weight dipakai	8.449 hari dari 9.000 hari

MCMC berhasil mengidentifikasi 12 bug issues optimal yang dapat diselesaikan dalam kapasitas 9.000 hari, memanfaatkan 93,9% kapasitas yang tersedia. Acceptance rate 33,34% menunjukkan eksplorasi yang seimbang antara solusi baru dan eksploitasi solusi terbaik.

VII. RECOMMENDATIONS

Berdasarkan seluruh temuan statistik di atas, berikut adalah rekomendasi konkret yang dapat ditindaklanjuti oleh pemelihara repositori pandas-dev/pandas:

7.1 Rekomendasi 1: Pertahankan Standar Review Saat Ini

Tingkat merge PR sebesar 62.09% yang terbukti secara statistik lebih tinggi dari klaim historis 60% ($p\text{-value} = 0.006$) menunjukkan bahwa proses code review saat ini berjalan efektif.

Pemelihara disarankan untuk mempertahankan dan mendokumentasikan standar review yang ada agar dapat diwariskan kepada maintainer baru.

7.2 Rekomendasi 2: Siapkan Kapasitas Tambahan Pasca Major Release

Analisis EDA menunjukkan adanya lonjakan ekstrem jumlah issue hingga 31 per minggu pada periode tertentu, yang kemungkinan berkaitan dengan rilis versi baru. Pemelihara disarankan untuk menjadwalkan penambahan reviewer atau triage volunteer pada minggu-minggu setelah major release untuk mencegah penumpukan issue yang tidak tertangani.

7.3 Rekomendasi 3: Terapkan Sistem Prioritisasi Bug Berbasis Data

Hasil Monte Carlo menunjukkan 66,77% issues membutuhkan lebih dari 30 hari untuk diselesaikan dengan median 297 hari mengindikasikan backlog yang panjang. Maintenance disarankan menerapkan prioritisasi berbasis MCMC untuk memaksimalkan throughput bug yang terselesaikan per periode. Selain itu, Bloom Filter dengan $FPR < 0,004\%$ dapat diimplementasikan pada pipeline triage otomatis untuk menyaring bug report baru secara efisien tanpa membebani memori sistem.

Link Github:

https://github.com/tatac6375-ops/stat-audit-pandas_dev_pandas-sti-2025.git

Link Video:

https://drive.google.com/drive/folders/1Ai-hIo2c19larTU8NahaHQIkrIxGRP_x?usp=drive_link